



Modele ekstrapolacyjne

Natalia Nehrebecka

4

Plan zajęć

1. Metody naiwne
2. Metoda średniej ruchomej
 - Prostej
 - A.** Prognozowanie
 - ważonej
3. Wygładzanie wykładnicze
 - Prosty model wygładzania wykładniczego
 - Model liniowy Holta
 - Model Wintersa
 - moltiplikatywny
 - addytywny

Interpolacja i ekstrapolacja

- ▶ **Interpolacja** polega na wyznaczeniu na podstawie danych o zjawisku jego wartości pośrednich (przebiegu funkcji) z wykorzystaniem metod matematycznych.
- ▶ W metodologii badań ekstrapolacja to inaczej prognozowanie na podstawie poznanych przypadków na całą populację.
- ▶ **Ekstrapolacja** polega na określaniu wartości zjawiska (przebiegu funkcji), dla wartości argumentu wychodzącego poza jego dziedzinę.

Ekstrapolacja

- ▶ Model ekstrapolacyjne są głównie stosowane do:
- ▶ **wygładzania szeregów czasowych**
 - oryginalne wartości y_t są zastąpione przez wartości wygładzone y_t^* w całym okresie próby (ang. **in-sample period**).
- ▶ **prognozowania szeregów czasowych**
 - prognozy y_{t+1} budowane są na podstawie wartości wygładzonych y_{t+1}^* w okresie prognozy (ang. **out-of-sample period**)

Plan zajęć

1. Metody naiwne
2. Metoda średniej ruchomej
 - prostej
 - ważonej
3. Wygładzanie wykładnicze
 - Prosty model wygładzania wykładniczego
 - Model liniowy Holta
 - Model Wintersa
 - moltiplikatywny
 - addytywny

Metody naiwne

- ▶ Oparte na przesłankach **braku zmian w zachowaniu czynników oddziałujących na zmienną prognozowaną**.
- ▶ Stosowane w przypadku niedużych wahań przypadkowych zmiennej zależnej.
- ▶ **Zalety:**
 - Łatwe w zrozumieniu, szybkie i tanie w zastosowaniu.
- ▶ **Wady:**
 - Umożliwiają prognozowanie **na jeden okres** na przód:
$$t = T_s + 1$$
 - Charakteryzuje je na ogół **niska jakość prognoz**.

Metody naiwne

- ▶ Prosta metoda naiwna:

$$y_{t+1}^* = y_t$$

gdzie:

- ▶ y_{t+1}^* - wygładzona wartość y_{t+1} na moment $(t + 1)$
- ▶ y_t - wartość zmiennej zależnej na moment (t)

Plan zajęć

1. Metody naiwne
2. Metoda średniej ruchomej
 - prostej
 - ważonej
3. Wygładzanie wykładnicze
 - Prosty model wygładzania wykładniczego
 - Model liniowy Holta
 - Model Wintersa
 - moltiplikatywny
 - addytywny

Metody średniej ruchomej


- ▶ Modele średniej ruchomej (ang. *moving average*) wykorzystywane są do:
- ▶ **wyrównania (wygładzania)** przebiegu szeregu czasowego
 - zastąpienie pierwotnych wartości zmiennej średnimi arytmetycznymi
- ▶ **prognozowania szeregu czasowego**
 - Stosowane są w przypadku występowania jedynie **małych wahań przypadkowych zmiennej zależnej!**
 - wartość prognozy jest równa średniej arytmetycznej z k ostatnich wartości tej zmiennej

$$y^*_{t+1} = \frac{y_t + y_{t-1} + \dots + y_{t-k+1}}{k}$$

gdzie:

- ▶ k – czynnik wygładzania

Prosta średnia ruchoma



Agenda

- ▶ Prognozowanie
 - Wprowadzenie
 - Ocena jakości prognoz
 - Praktyka

Czemu służą prognozy?

- ▶ Prognoza = próba przewidzenia rozwoju analizowanego zjawiska w przyszłości
 - (*kierunek i/lub wielkość zmiany*).
- ▶ Prognozuje się, ponieważ jest to użyteczne.
 - Czasem wystarczy przewidzieć *kierunek zmiany*, żeby dużo zarobić, np. wzrost kursu akcji następnego dnia – **nie istnieje model doskonały**.
 - Z drugiej strony model przewidujący np., że indeks cen (CPI) wzrośnie z miesiąca na miesiąc jest bezużyteczny – przez ostatnie 40 lat spadek cen zanotowano w 1% przypadków.

Przykładowe nietrafione prognozy

- ▶ **„Wszystko co było do wynalezienia zostało już wynalezione.”**
– Dyrektor Amerykańskiego Biura Patentowego, 1899.
- ▶ **„Ceny akcji osiągnęły jak się wydaje dość wysoki, stabilny poziom.”** – prof. Irving Fisher, Yale University, 16.10.1929.
- ▶ **„Myślę, że na całym świecie może być zapotrzebowanie na jakieś 5 komputerów.”** – członek Zarządu IBM, 1943.
- ▶ **„Komputery w przyszłości mogą ważyć nie więcej niż 1,5 tony.”** – Popular Mechanics, prognoza nieustającego postępu nauki, 1949.
- ▶ **„640 kB powinno wystarczyć każdemu.”** – Bill Gates, 1981

Koncepcja trafności prognozy

- ▶ Nie ma prognoz doskonałych, każda jest obarczona **błędem**
- ▶ Mogą być one jednak użyteczne jeśli zapewniają ***lepsz***
odpowiedzi na zadane pytania niż metody alternatywne, czy
proste zgadywanie
- ▶ Testem trafności prognozy nie jest więc jej bezbłędność, ale
porównanie jej dokładności z prognozami alternatywnymi

Pułapki w trakcie prognozowania

- ▶ Nawet jeśli wszystkie założenia modelu są spełnione i wszystkie procedury statystyczne poprawnie zastosowane – *pojawia się błąd losowy prognozy.*
- ▶ **Wielkość oczekiwanego błędu prognozy można oszacować.**
- ▶ W praktyce empirycznej rzeczywisty błąd prognozy jest większy niż spodziewany.
- ▶ **Paradoks:** model niespełniający założeń może być użyteczny do prognozowania.

Błąd prognozy ex post

- ▶ Z okresu, dla którego dysponujemy obserwacjami $[1, T]$, wydzielamy okres próby (okres *in-sample* - $[1, T_s]$).
 - Na wydzielonej części próby szacujemy parametry modelu.
- ▶ Wykonujemy prognozę na okres *out-of-sample* $[T_{s+1}, T]$.
 - Obliczamy błąd prognozy ex-post w okresie *out-of-sample*.

Błąd prognozy ex post

- ▶ Błąd prognozy:

$$e_t = y_t - y_t^*$$

gdzie:

- zmienna prognozowana y_t
- prognoza zmiennej y_t^*

Błąd prognozy ex post

- ▶ MAE – *Mean Absolute Error*, średni **bezwzględny** błąd prognozy

$$\frac{1}{T - T_s} \sum_{t=T_s+1}^T |e_t|$$

- Nie spełnia warunku unormowania

- ▶ MSE – *Mean Square Error*, średni kwadratowy błąd prognozy

$$\frac{1}{T - T_s} \sum_{t=T_s+1}^T (e_t)^2$$

- Nie spełnia warunku unormowania

Błąd prognozy ex post

- ▶ MAPE – *Mean Absolute Percentage Error*, średni względny błąd prognozy

$$\frac{100\%}{T - T_s} \sum_{t=T_s+1}^T \left| \frac{e_t}{y_t} \right|$$

- Jaki procent rzeczywistej wartości zmiennej y stanowiło przeciętne w przedziale weryfikacji bezwzględne odchylenie prognoz od danych rzeczywistych.

- ▶ AMAPE – *Adjusted MAPE*, skorygowany średni względny błąd prognozy

$$\frac{100\%}{T - T_s} \sum_{t=T_s+1}^T \left| \frac{e_t}{y_t + y_t^*} \right|$$

Błąd prognozy ex post

- ▶ MAPE – Mean Absolute Percentage Error, średni **względny** błąd prognozy

$$\frac{100\%}{T - T_s} \sum_{t=T_s+1}^T \left| \frac{e_t}{y_t} \right|$$

- *Nie spełnia warunku symetrii*, tj. wyżej ocenia przeszacowanie prognoz niż ich niedoszacowanie

$$y_{T_s+1} = 120; \quad \hat{y}_{T_s+1} = 80; \quad MAPE = 33,3\%$$

$$y_{T_s+1} = 80; \quad \hat{y}_{T_s+1} = 120; \quad MAPE = 50\%$$

Błąd prognozy ex post

- ▶ AMAPE – Adjusted MAPE, skorygowany średni **względny** błąd prognozy

$$\frac{100\%}{T - T_s} \sum_{t=T_s+1}^T \left| \frac{e_t}{y_t + y_t^*} \right|$$

- Wartość tego błędu należy do przedziału [0,100%]
- Spełnia warunek symetrii

Wady i zalety poszczególnych miar jakości prognoz ex-post

- ▶ Miary bezwzględne (**MSE, MAE**) mają lepsze właściwości dla szeregów o **wartościach większych co do modułu od 1**, dla szeregów których wyrazy są **mniejsze co do modułu od 1** preferowane są **miary względne (MAPE, AMAPE)**.
- ▶ Dla szeregów które przyjmują zarówno **dodatnie jak i ujemne wartości** lepsze są *miary absolutne*.
 - Zatem MSE jest dobrą miarą dla szeregów o wartościach większych od 1, MAE jest dobrą miarą dla szeregów o wartościach absolutnych większych od 1. Dodatkowo jest bardziej odporna na występowanie obserwacji nietypowych.
- ▶ MAPE może być interpretowany jako błąd procentowy, jest ograniczony z dołu przez 0,
- ▶ AMAPE *koryguje problem asymetrii* między wartościami rzeczywistymi a prognozami.

Plan zajęć

1. Metody naiwne
2. **Metoda średniej ruchomej**
 - prostej
 - ważonej
3. Wygładzanie wykładnicze
 - Prosty model wygładzania wykładniczego
 - Model liniowy Holta
 - Model Wintersa
 - moltiplikatywny
 - addytywny

Metody średniej ruchomej

- ▶ Modele średniej ruchomej (ang. *moving average*) wykorzystywane są do:
- ▶ **wyrównania (wygładzania)** przebiegu szeregu czasowego
 - zastąpienie pierwotnych wartości zmiennej średnimi arytmetycznymi
- ▶ **prognozowania szeregu czasowego**
 - Stosowane są w przypadku występowania jedynie **małych wahań przypadkowych zmiennej zależnej!**
 - wartość prognozy jest równa średniej arytmetycznej z k ostatnich wartości tej zmiennej

$$y^*_{t+1} = \frac{y_t + y_{t-1} + \dots + y_{t-k+1}}{k}$$

gdzie:

- ▶ k – czynnik wygładzania

Jak wyznaczyć stałą k ?

- ▶ Można wykorzystać błędy prognozy *ex post*, np.

$$\frac{1}{T - k} \sum_{t=k+1}^T (e_t)^2$$

- ▶ Wybieramy tę wartość k , dla którego MSE jest najmniejsze.
- ▶ Dla $k = 1$ model sprowadza się do metody naiwnej.

Prosta średnia ruchoma

- ▶ **Wadą** średniej ruchomej jest przypisywanie takiego samego znaczenia obserwacjom *odległym w czasie i najnowszym*

$$y_{t+1}^* = \frac{1}{k} y_t + \frac{1}{k} y_{t-1} + \cdots + \frac{1}{k} y_{t-k+1}$$

Ważona średnia ruchoma

- ▶ Ważona średnia ruchoma daje **większe wagi** obserwacjom *najnowszym*
- ▶ Typowy przykład:

$$y_{t+1}^* = \frac{1}{21} \sum (6y_t + 5y_{t-1} + 4y_{t-2} + 3y_{t-3} + 2y_{t-4} + 1y_{t-5})$$

Ważona średnia ruchoma

- ▶ Ogólnie:

$$y_{t+1}^* = \sum_{i=t-k+1}^t y_i w_{i-t+k}$$

- ▶ Wagi muszą spełniać następujące warunki:

- $0 < w_1 < w_2 < \dots < w_k \leq 1$
- $\sum_{i=1}^k w_i = 1$

Dziękuję za uwagę