





# Stacjonarność

**Natalia Nehrebecka**

**# 6**

# Szwecja, Rok 2003



Dlaczego ci panowie są tak uśmiechnięci?...

# Plan zajęć

- ▶ Stacjonarność, biały szum
- ▶ Random walk - błędzenie przypadkowe
- ▶ Trendy w szeregach czasowych
- ▶ Zmienne zintegrowane

# Plan zajęć

- ▶ Stacjonarność, biały szum
- ▶ Random walk - błędzenie przypadkowe
- ▶ Trendy w szeregach czasowych
- ▶ Zmienne zintegrowane

# Silna stacjonarność

- ▶ Proces stochastyczny jest **silnie stacjonarny** lub ściśle stacjonarny jeśli **łącznie rozkłady jego zmiennych nie zmieniają się w czasie**.
  - W rezultacie, parametry takie jak wartość oczekiwana i wariancja, jeśli istnieją, także pozostają stałe w czasie.
- ▶ Formalnie, jeśli
  - $\{X_t\}$  jest procesem stochastycznym, oraz
  - $F_X(x_{t_1+\tau}, \dots, x_{t_k+\tau})$  opisuje dystrybuantę rozkładu łącznego zmiennych  $\{X_t\}$  w momentach  $t_1 + \tau, \dots, t_k + \tau$ ,to
  - **$\{X_t\}$  jest procesem stacjonarnym, jeśli  $\forall k, \forall \tau, \forall t_1, \dots, t_k$**   
 **$F_X(x_{t_1+\tau}, \dots, x_{t_k+\tau}) = F_X(x_{t_1}, \dots, x_{t_k})$**

# Słaba stacjonarność

- ▶ Proces stochastyczny jest **stacjonarny w sensie słabym**, jeśli dla każdego  $t$  spełnione są trzy poniższe warunki:


$E(X_t) = \mu$  - wartość oczekiwana nie zależy od  $t$   
(*jest skończona i stała w czasie*)

$Var(X_t) = \sigma^2$  - wariancja nie zależy od  $t$   
(*jest skończona i stała w czasie*)

$Cov(X_t, X_{t+h}) = \sigma_h$  - wartość kowariancji dla dwóch obserwacji zależy jedynie od *odstępu* między nimi, a nie od momentów czasu z których pochodzą obserwacje


# Proces stochastyczny niestacjonarny

- ▶ Proces stochastyczny z rosnącą (niestacjonarną) wartością oczekiwaną:



# Stacjonarny proces stochastyczny

- ▶ Proces stochastyczny ze stałą (stacjonarną) wartością oczekiwaną i stałą wariancją:



- ▶ **Uwaga!**
- ▶ Nie możemy nic powiedzieć o kowariancji na podstawie tego wykresu!



# Słaba stacjonarność

$Cov(X_t, X_{t+h}) = \sigma_h$  - wartość kowariancji dla dwóch obserwacji zależy jedynie od odstępu między nimi, a nie od momentów czasu z których pochodzą obserwacje

np.

(A) Korelacja dla szeregu z roku **1980** i **1985** jest taka sama jak dla lat **1990** i **1995** (czyli  $t = 1980$  oraz  $1990$ ,  $h = 5$ )

(B) Korelacja dla szeregu z roku **1980** i **1987** jest taka sama jak dla lat **1990** i **1997** (czyli  $t = 1980$  i  $1990$ ,  $h = 7$ )

# Zmienne stacjonarne

zmienna stacjonarna



zmienna, której własności **nie zmieniają się wraz z upływem czasu**

- istnieje kilka **definicji stacjonarności**, my będziemy posługiwać się pojęciem **słabej (kowariancyjnej) stacjonarności**:

# Zmienne stacjonarne



- 1.  $E(y_t) = \mu < \infty$  wartość oczekiwana  $y_t$  jest skończona i stała w czasie
- 2.  $Var(y_t) = \sigma^2 < \infty$  - wariancja  $y_t$  jest skończona i stała w czasie
- 3.  $Cov(y_{t_1}, y_{t_1+h}) = Cov(y_{t_2}, y_{t_2+h}) = \gamma_h$  kowariancja między realizacjami  $y_t$  zależy jedynie od dystansu w czasie  $h$



któryś z warunków niespełniony= zmienna niestacjonarna



# Zmienne stacjonarne

- 1.  $E(y_t) = \mu < \infty$  wartość oczekiwana  $y_t$  jest skończona i stała w czasie



# Zmienne stacjonarne

- 2.  $Var(y_t) = \sigma^2 < \infty$  - wariancja  $y_t$  jest skończona i stała w czasie



# Zmienne stacjonarne

- ▶ założenie o stacjonarności zmiennych w modelu jest niezbędne przy **wyprowadzaniu rozkładów typowych statystyk testowych używanych przy testowaniu hipotez**
- ▶ badanie stacjonarności zmiennych w modelu może być traktowane jako test diagnostyczny **→** weryfikuje prawdziwość założeń koniecznych do tego, by standardowe procedury testowania hipotez były prawidłowe

# Zmienne stacjonarne

- ▶ Proces białego szumu (**white noise**) spełnia następujące założenia:

$$E(y_t) = \mu$$

$$Var(y_t) = \sigma^2$$

$$Cov(y_t, y_s) = 0$$

# Zmienne stacjonarne

- ▶ Zero-mean white noise:

$$E(y_t) = 0$$


$$Var(y_t) = \sigma^2$$

$$Cov(y_t, y_s) = 0$$



# Przykład białego szumu

Biały szum – szereg stacjonarny



# Zmienne stacjonarne

- ▶ Independent (strong) white noise:

$$y_t \sim \text{IID}(0, \sigma^2)$$

*IID (Independently and Identically Distributed)*

- ▶ realizacje  $y_t$  są niezależne i mają identyczne rozkłady.

# Testowanie białego szumu

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_P = 0$$

$H_0$ : nie ma autokorelacji do rzędu  $P$  włącznie

$H_1$ : występuje autokorelacji rzędu od 1 do  $P$

## ■ Statystyka Q Boxa-Pierce'a

$$Q = T \sum_{k=1}^P \hat{\rho}_k^2 \sim \chi_P^2$$

## ■ Statystyka Q\* Ljunga-Boxa

▶ (lepsza dla małych prób)

$$Q^* = T(T+2) \sum_{k=1}^P \frac{\hat{\rho}_k^2}{T-k} \sim \chi_P^2$$

$$\hat{\rho}_k^2 = \frac{\sum_{t=k+1}^T e_t e_{t-k}}{\sum_{t=1}^T e_t^2}$$

W obu testach  $H_0$ : proces **jest** białym szumem

# Testowanie białego szumu

- ▶ Należy wybrać maksymalnie  $P$  do przetestowania
  - (24 opóźnienia dla autokorelacji zwykłej,
  - 3 dla sezonowej)


# Zmienne stacjonarne

- ▶ Przykład zmiennej stacjonarnej:  $AR(1)$

$$y_t = \alpha y_{t-1} + \varepsilon_t, \text{ gdzie } |\alpha| < 1$$

# Zmienne stacjonarne

- przykład zmiennej stacjonarnej:  $AR(1)$ :  $y_t = 0,7y_{t-1} + \varepsilon_t$



# Zmienne stacjonarne

- przykład zmiennej stacjonarnej:  $AR(1)$

$$y_t = \alpha y_{t-1} + \varepsilon_t \quad \varepsilon_t \sim IID(0, \sigma^2)$$
$$|\alpha| < 1$$

## Dowód stacjonarności:

1. Podstawiając  $y_{t-1} = \alpha y_{t-2} + \varepsilon_{t-1}$  do poprzedniego wzoru:

$$y_t = \alpha^2 y_{t-2} + \alpha \varepsilon_{t-1} + \varepsilon_t$$

2. Postępując tak rekurencyjnie

$$y_t = \sum_{i=0}^{\infty} \alpha^i \varepsilon_{t-i}$$

# Zmienne stacjonarne


$$\blacktriangleright E(y_t) = E(\sum_{i=0}^{\infty} \alpha^i \varepsilon_{t-i}) = \sum_{i=0}^{\infty} \alpha^i \underbrace{E(\varepsilon_{t-i})}_0 = 0$$

$$\blacktriangleright Var(y_t) = Var(\sum_{i=0}^{\infty} \alpha^i \varepsilon_{t-i}) = \sum_{i=0}^{\infty} \alpha^{2i} \underbrace{Var(\varepsilon_{t-i})}_{\sigma^2} = \frac{\sigma^2}{1-\alpha^2}$$

$$\blacktriangleright Cov(y_t, y_{t-h}) = \alpha^h \frac{\sigma^2}{1-\alpha^2}$$



# Zmienne stacjonarne



$$y_t = 20 + 0,7 \cdot y_{t-1} + \varepsilon_t$$

# Plan zajęć

- ▶ Stacjonarność, biały szum
- ▶ Random walk - błędzenie przypadkowe
- ▶ Trendy w szeregach czasowych
- ▶ Zmienne zintegrowane

# Droga do pubu - przykład zmiennej niestacjonarnej

- ▶ Stoimy między dwoma pubami i chcemy zdecydować, do którego pójść przy pomocy rzutu monetą.

- *orzeł* → *robimy krok w lewo*;
- *reszka* → *robimy krok w prawo*;

$$Z_t = \begin{cases} -1 & \text{z prawd. } p = 1/2 \\ 1 & \text{z prawd. } p = 1/2 \end{cases}$$

- ▶ Po każdym ruchu powtórnie rzucamy monetą, powtarzając całą operację, aż do celu (*dla uproszczenia przyjmujemy, że od każdego z pubów dzieli nas nieskończona liczba kroków*).

## Droga do pubu – cd.

- ▶ Możemy zatem zapisać:

$$\begin{aligned}X_1 &= Z_1 \\X_2 &= X_1 + Z_2 \\X_3 &= X_2 + Z_3 \\&\vdots \\X_t &= X_{t-1} + Z_t\end{aligned}$$

- ▶ Czy  $X_t$  jest zatem stacjonarny?
- ▶ Mamy co prawda:

$$E(X_t) = 0$$

- ▶ ale ...

## Droga do pubu – cd.

$$\text{Var}(X_1) = \text{Var}(Z_1) = 1$$

$$\text{Var}(X_2) = \text{Var}(X_1 + Z_2) = \text{Var}(X_1) + \text{Var}(Z_2) = 2$$


$$\text{Var}(X_3) = \text{Var}(X_2) + \text{Var}(Z_3) = 3$$

$$\ddots$$
$$\text{Var}(X_t) = t$$

- ▶ Wariancja procesu  $X_t$  jest liniową funkcją czasu, więc jest to proces niestacjonarny!
- ▶ Jest to szczególny przypadek ważnego niestacjonarnego procesu, nazywanego **błądzeniem przypadkowym** (*random walk*).

# Droga do pubu: skokowy proces błędzenia losowego

- ▶ Nawet jeśli mamy do pubu 20 kroków możemy tam długo nie dotrzeć



# Zmienna niestacjonarna:

## proces błędzenia losowego

### Proces błędzenia losowego – definicja

$$y_t = y_{t-1} + \varepsilon_t$$

$$y_t = y_{t-1} + \varepsilon_t = y_{t-2} + \varepsilon_{t-1} + \varepsilon_t = y_{t-3} + \varepsilon_{t-2} + \varepsilon_{t-1} + \varepsilon_t = \dots =$$

$$y_0 + \sum_{t=1}^T \varepsilon_t \stackrel{y_0=0}{=} \underbrace{\sum_{t=1}^T \varepsilon_t}_{\text{trend stochastyczny}}$$

trend stochastyczny

### Własności błędzenia losowego

$$E(y_t) = E\left(\sum_{t=1}^T \varepsilon_t\right) = \sum_{t=1}^T E(\varepsilon_t) = 0$$

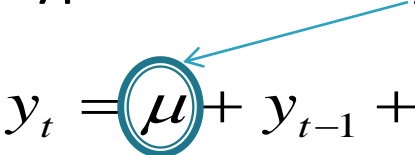
$$D^2(y_t) = D^2\left(\sum_{t=1}^T \varepsilon_t\right) \stackrel{\text{cov}(\varepsilon_t, \varepsilon_{t-h})=0}{=} \sum_{t=1}^T D^2(\varepsilon_t) = T\delta^2$$

$$\text{cov}(y_t, y_{t-h}) = E(y_t, y_{t-h}) - E(y_t)E(y_{t-h}) = E\left(\sum_{t=1}^{T-h} \varepsilon_t \sum_{t=1}^{T-h} \varepsilon_t\right) -$$

$$\underbrace{E\left(\sum_{t=1}^{T-h} \varepsilon_t\right)}_0 \underbrace{E\left(\sum_{t=1}^{T-h} \varepsilon_t\right)}_0 = D^2\left(\sum_{t=1}^{T-h} \varepsilon_t\right) = \sum_{t=1}^{T-h} D^2(\varepsilon_t) = (T-h)\delta^2$$

# Proces błędzenia przypadkowego


- ▶ Błądzenie przypadkowe z dryfem:

$$y_t = \mu + y_{t-1} + \varepsilon_t$$


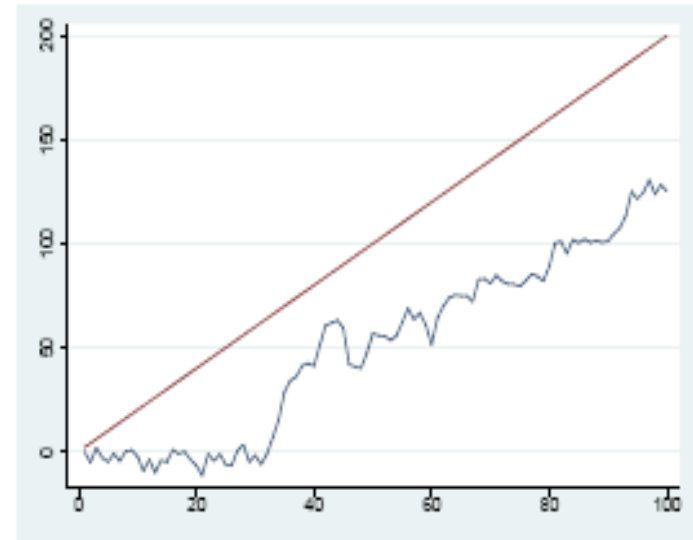

- ▶ Dryf to systematyczne znoszenie w jednym kierunku o tej samej wielkości w każdym kroku.



# Błądzenie przypadkowe - z dryfem i bez dryfu



# Błądzenie przypadkowe - z dryfem i bez dryfu



# Zmienna niestacjonarna:

## Błądzenie przypadkowe - z dryfem

### Proces błędzenia losowego z dryfem – definicja

$$y_t = \alpha_0 + y_{t-1} + \varepsilon_t$$

$$y_t = \alpha_0 + y_{t-1} + \varepsilon_t = \alpha_0 + \alpha_0 + y_{t-2} + \varepsilon_{t-1} + \varepsilon_t =$$

$$\alpha_0 + \alpha_0 + \alpha_0 + y_{t-3} + \varepsilon_{t-2} + \varepsilon_{t-1} + \varepsilon_t = \dots \stackrel{y_0=0}{=} T\alpha_0 + \underbrace{\sum_{t=1}^T \varepsilon_t}_{\text{trend stochastyczny}}$$

### Własności błędzenia losowego z dryfem

$$E(y_t) = E(T\alpha_0 + \sum_{t=1}^T \varepsilon_t) = T\alpha_0 + \sum_{t=1}^T E(\varepsilon_t) = T\alpha_0$$

Wariancja i kowariancja takie same, jak w przypadku błędzenia przypadkowego, bo przesunięcie o stałą nie wpływa na dyspersję procesu.

# Plan zajęć

- ▶ Stacjonarność, biały szum
- ▶ Random walk - błędzenie przypadkowe
- ▶ Trendy w szeregach czasowych
- ▶ Zmienne zintegrowane

# Trend stochastyczny

- ▶ W ekonomii często na podstawie badania szeregu czasowego można stwierdzić z jakim typem niestacjonarności mamy do czynienia.
- ▶ Jeżeli polega ona na tym, że szereg ma skłonność do poruszania się w jednym kierunku, nazywamy taką tendencję **trendem**.
- ▶ Szereg może powoli dryfować w górę lub w dół wyłącznie w rezultacie stochastycznych (losowych) szoków. Nazwiemy go wtedy szeregiem czasowym z **trendem stochastycznym**.

# Trend deterministyczny


- ▶ Innym przykładem tendencji rozwoju niestacjonarnego procesu stochastycznego jest sytuacja, gdy **średnia procesu jest funkcją czasu**.
- ▶ Ogólnym zapisem takiej funkcji jest wielomian zmiennej czasowej stopnia  $k$ , który zapiszemy w postaci:

$$S_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \dots + \beta_k t^k$$

- ▶ Funkcja taka nazywana jest **trendem deterministycznym**. Szczególnym przypadkiem takiej funkcji jest trend liniowy:

$$S_t = \beta_0 + \beta_1 t$$

# Trend stochastyczny vs. trend deterministyczny





# Komentarz

- ▶ Proces błędzenia przypadkowego (z dryfem lub bez) i trendy deterministyczne wydają się sensownym odzwierciedleniem wielu makroekonomicznych szeregów czasowych (może występować również ich kombinacja).
- ▶ Oba rodzaje procesów dają **niestacjonarne szeregi o silnym trendzie**. Nie jest więc zaskakujące, że regresje tego typu zmiennych względem siebie niemal zawsze dają **istotne statystycznie wyniki** (relacje).
- ▶ Zależność ta jednak (silna korelacja między nimi) może być wynikiem podobnego trendu, niezależnie od rzeczywistego występowania między nimi relacji regresyjnej.



# Szwecja, Rok 2003



Dlaczego ci panowie są tak uśmiechnięci?...

# „Stara Ekonometria”



$$\begin{array}{l} \text{Zmienna} \\ \text{zależna} \end{array} = f ( \text{zmienne niezależne} ) + \begin{array}{l} \text{drobne} \\ \text{odchylenia} \\ \text{losowe} \end{array}$$

Ekonometria wyjaśnia relacje pomiędzy zmiennymi ekonomicznymi i pokazuje zależności w postaci formuł matematycznych

Opiera się na statystycznej analizie danych historycznych

*Gospodarka narodowa, banki, journal of marketing...*

# „Nowa Ekonometria” W Autorskim Ujęciu Poetyckim

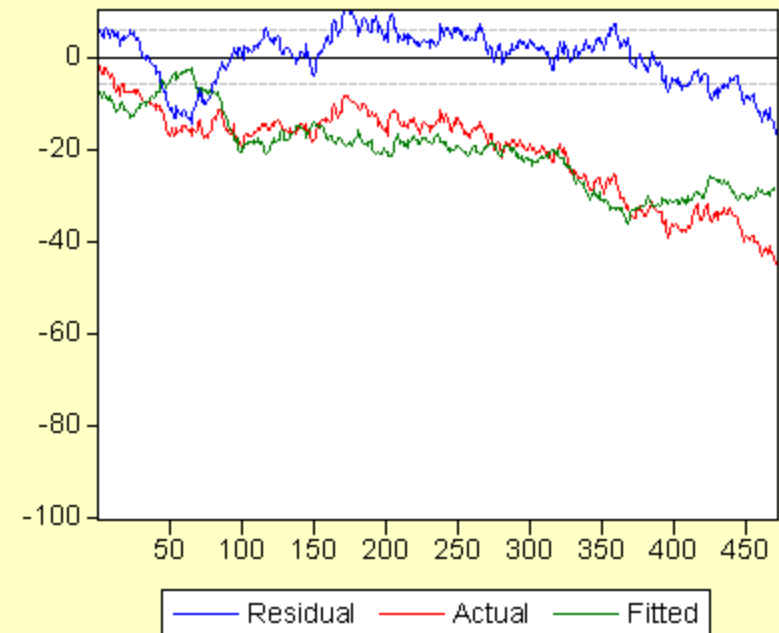
- Każda zmienna ma swoją duszę, coś co kieruje jej poczynaniami; to, co widzimy, to tylko ciało – fizyczna realizacja
- Tę duszę możemy odkryć...
- **Podstawą** do opisania rzeczywistości ekonomicznej jest jej **przeszłość**
- Występują **pozorne zależności** pomiędzy pewnymi zmiennymi ekonomicznymi. Należy ostrożnie postępować, żeby się wystrzec fałszywych wniosków!



# Zinterpretujmy Model...

Dependent Variable: RW2  
Method: Least Squares  
Date: 14/12/07 Time: 07:03  
Sample: 1 470  
Included observations: 470


Variable	Coefficient	Std. Error	t-Statistic	Prob.
RW1	0.725818	0.023532	30.84337	0.0000
C	-7.142068	0.503242	-14.19212	0.0000
<hr/>				
R-squared	0.670263	Mean dependent var	-20.40957	
Adjusted R-squared	0.669559	S.D. dependent var	9.850255	
S.E. of regression	5.662324	Akaike info criterion	6.309792	
Sum squared resid	15004.98	Schwarz criterion	6.327463	
Log likelihood	-1480.801	F-statistic	951.3134	
Durbin-Watson stat	0.044606	Prob(F-statistic)	0.000000	




**Jedynie wartość DW wskazuje, że coś jest nie w porządku!**

# A Co Na To NOWA Ekonometria?

Młody Człowieku, nie  
zrobiłbyś tego błędu,  
badając stacjonarność!



Ha, ha, ha...  
Frajer!...



- Zmienne ekonomiczne przed modelowaniem trzeba odpowiednio przygotować!!!

# Uwaga!

- ▶ Regresje dla szeregów czasowych niestacjonarnych (zawierających trend deterministyczny lub stochastyczny) często dają pozornie dobre wyniki.
- ▶ W ten sposób uniemożliwiają stwierdzenie, czy związki ekonomiczne wynikające z teorii są rzeczywiście poparte, czy też nie, wynikami empirycznymi.
- ▶ **Analiza regresji ma sens jedynie dla danych, które nie podlegają trendowi.**
- ▶ **Ponieważ wszystkie ekonomiczne szeregi czasowe zawierają trend, należy go usunąć przed przeprowadzaniem analizy regresji.**

# Regresje pozorne

- ▶ Własności statystyczne analizy regresji niestacjonarnych szeregów czasowych są na ogół wątpliwe.
- ▶ Dodatkowo występuje wysokie prawdopodobieństwo uzyskania istotnych wyników, nawet gdy w rzeczywistości one nie występują (regresje pozorne).
- ▶ Taka sytuację nazywamy **regresja pozorna** (*spurious regression*).

# Regresje pozorne: trend deterministyczny

Regresja trendu liniowego względem trendu kwadratowego:

$$y = 1, 2, 3, \dots, n$$

$$x = 1, 4, 9, \dots, n^2$$

**reg y x**

Source	SS	df	MS	Number of obs = 50		
Model	9786.41053	1	9786.41053	F( 1, 48)	=	750.29
Residual	626.08947	48	13.0435306	Prob > F	=	0.0000
				R-squared	=	0.9399
				Adj R-squared	=	0.9386
Total	10412.5	49	212.5	Root MSE	=	3.6116

y	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
x	.0184289	.0006728	27.39	0.000	.0170761	.0197816
_cons	9.678832	.7710305	12.55	0.000	8.128571	11.22909


**estat dwatson**

Durbin-Watson d-statistic( 2, 50) = .021547

**Jedynie DW wskazuje, że coś jest nie w porządku!**



# Wartości teoretyczne vs. rzeczywiste



# Regresje pozorne: trend stochastyczny

- ▶ Eksperyment Newbolda i Davisa
- ▶ Generujemy obserwacje dwóch **niezależnych** zmiennych niestacjonarnych;

$$y_t = y_{t-1} + \varepsilon_{1t}, \quad \varepsilon_{1t} \sim N(0,1)$$

$$x_t = x_{t-1} + \varepsilon_{2t}, \quad \varepsilon_{2t} \sim N(0,1)$$

$$\text{Cov}(\varepsilon_{1t}, \varepsilon_{2t}) = 0$$

- ▶ Liczymy prostą regresję jednej zmiennej na drugą;

$\varepsilon_{1t}$  na  $\varepsilon_{2t}$  oraz  $y_t$  na  $x_t$

- ▶ Sprawdzamy istotność relacji (*test t*);
- ▶ Powtarzamy eksperyment odpowiednio dużą liczbę razy zapisując wyniki;
- ▶ **Przy poziomie istotności 5%** powinniśmy uzyskać **istotny wynik w mniej więcej 5% przypadków**

# Wyniki dla 1000 powtórzeń

regresja zmiennych  
stacjonarnych

regresja zmiennych  
niestacjonarnych

	teoretyczne	e1 na e2	y na x
	statystyki t		
średnia	0,000	0,036	0,048
odch . std	1,021	1,015	4,849
skośność	0,000	-0,151	-0,214
kurtoza	3,125	3,482	3,845
5% percentyl	1,677	1,564	8,294
% 'istotnych' wyników	5,000	5,200	64,200
	statystyka DW		
średnia	2,000	1,994	0,313

- ▶  $x, y$  generowane niezależnie, więc zależności między nimi w rzeczywistości nie ma;
- ▶ Tymczasem wyniki pokazują „istotną” zależność w 64% przypadków !!!
- ▶ Regresje te miały również bardzo niską (średnio 0,313) wartość statystyki DW wskazującą na silną dodatnią autokorelację reszt.

# Regresje pozorne: trend stochastyczny

- ▶ Eksperyment Newbolda i Davisa
- ▶ Dla równania regresji, dla niestacjonarnych szeregów:

$$y_t = \beta_1 + \beta_2 x_t + \varepsilon_t$$

- ▶ Pokazano, że statystyka:

$$t = \frac{b_2}{se(b_2)}$$

- ▶ nie ma rozkładu  $t$  – *Studenta*.
  - W ramach prostego eksperymentu Monte Carlo porównano wartości krytyczne testu dla powyższej regresji z wartościami teoretycznymi!

nie da się przeprowadzić wnioskowania przy użyciu standardowych statystyk testowych, jednak *estymator MNK jest nadal estymatorem zgodnym*

# Plan zajęć

- ▶ Stacjonarność, biały szum
- ▶ Random walk - błędzenie przypadkowe
- ▶ Trendy w szeregach czasowych
- ▶ Zmienne zintegrowane

# Zmienne zintegrowane

- ▶ *zmienne zintegrowane:*
  - **zmienne niestacjonarne**, które można sprowadzić do stacjonarności poprzez różnicowanie
- ▶ **Engle i Granger (1987)**
  - zmienna, która po zastosowaniu  $d$ -tych różnic staje się zmienną stacjonarną oznaczamy jako:

$$y_t \sim I(d)$$

- mówimy, że zmienna  $y_t$  jest zintegrowana rzędu  $d$

# Zmienne zintegrowane

- ▶ zmienne stacjonarne są zintegrowane rzędu 0:

$$y_t \sim I(0)$$

# Zmienne zintegrowane

- przykład zmiennej niestacjonarnej: **błądzenie przypadkowe**

$$y_t = y_{t-1} + \varepsilon_t \quad \varepsilon_t \sim IID(0, \sigma^2)$$

- różnicując zmienną  $y_t$  (odejmując od obu stron  $y_{t-1}$ ):

$$\Delta y_t = \varepsilon_t \quad - \text{biały szum, zmienna } I(0)$$

- wobec tego **błądzenie przypadkowe jest zmienną  $I(1)$**



# Uwaga 1!

Szereg nie musi być białym szumem (*white noise*), żeby być stacjonarnym!

# Zmienne zintegrowane

- uważa się, że znaczna część zmiennych makroekonomicznych jest  $I(1)$
- istnieją też zmienne ekonomiczne, które są  $I(2)$
- zmienne  $I(3)$  stanowią wśród zmiennych ekonomicznych rzadkość albo nie występują wcale

# Uwaga 2!

- ▶ Uogólniając, możemy wyróżnić dwa rodzaje niestacjonarności

**1. błędzenie losowe z dryfem lub bez**, tj. szereg przyrostowo-stacjonarny (*difference-stationary process*)

$$y_t = \mu + y_{t-1} + \varepsilon_t$$

**2. trend deterministyczny**, tj. szereg trendo-stacjonarny (*deterministic non-stationarity, trend-stationary process*)

$$y_t = \alpha + \beta t + \varepsilon_t$$

- ▶ **Oba rodzaje niestacjonarności związane są z występowaniem trendów, wymagają one odmiennej procedury potrzebnej do osiągnięcia stacjonarności.**

## Uwaga 2!

- ▶ Jeśli mamy powody by uważać, że **szereg jest trendo-stacjonarny**, to właściwym podejściem jest **regresja na trendzie liniowym**, a następnie dalsza analiza na resztach pochodzących z tego równania.
- ▶ Jeśli natomiast wydaje się, że szereg zawiera tylko **trendy stochastyczne**, to rozwiązaniem jest **przeprowadzenie różnicowania** – zwykle jednokrotnego, rzadziej dwukrotnego.

# Uwaga 3!

- ▶ Jeśli **pierwsze różnice** policzymy dla szeregu trendo-stacjonarnego to, co prawda usuniemy w ten sposób niestacjonarność, lecz przy okazji wprowadzimy do błędu losowego strukturę **MA(1)** (moving average process) -> o tym więcej na pozostałych zajęciach:

$$y_t = \alpha + \beta t + \varepsilon_t$$

- ▶ w  $t-1$ :

$$y_{t-1} = \alpha + \beta(t-1) + \varepsilon_{t-1}$$

- ▶ Odejmując:

$$\Delta y_t = \beta + \varepsilon_t - \varepsilon_{t-1}$$

- ▶ powstała struktura MA (średniej ruchomej) **jest nieodwracalna (*non-invertible*)**, tj. nie można jej przedstawić w postaci procesu autoregresyjnego (o tym więcej na pozostałych zajęciach).
- ▶ **A zatem,  $y_t$  będzie posiadał w tym przypadku bardzo niepożądane własności.**

## Uwaga 3!

- ▶ Podobną sytuację otrzymamy, jeśli spróbujemy usunąć trend liniowy za pomocą regresji zmiennej zawierającej trend stochastyczny.

**Dziękuję za uwagę**