



Modele autoregresyjne ze średnią ruchomą $ARMA(p,q)$

8

Natalia Nehrebecka

Plan zajęć

- ▶ Procesy AR, MA, ARMA, ARIMA i ARIMAX
- ▶ Procedura Boxa-Jenkinsa
- ▶ Prognozy

Plan zajęć

- ▶ Procesy AR, MA, ARMA, ARIMA i ARIMAX
- ▶ Procedura Boxa-Jenkinsa
- ▶ Prognozy

Wprowadzenie

- ▶ modele ARMA - geneza w pracach Boxa i Jenkinsa w latach 70. XX w.
- ▶ **jednowymiarowa analiza szeregów czasowych:** wiedza o przyszłości szeregu „zaklęta” w jego przeszłości :-)
- ▶ podstawowe zastrzeżenia:
 - tylko do szeregów stacjonarnych
 - tylko do prognoz **krótkookresowych**
 - model ateoretyczny

Model AR(p)

► *AR* (ang. *autoregression*):

- w procesie autoregresyjnym bieżąca wartość zmiennej zależnej y_t zależy tylko od swoich opóźnionych wartości oraz błędu losowego.

$$\mathbf{AR}(p): y_t = \mu + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \dots + \alpha_p y_{t-p} + \varepsilon_t,$$

gdzie: $\varepsilon_t \sim WN$

Notacja wielomianu charakterystycznego:

$$\underbrace{(1 - \alpha_1 L - \alpha_2 L^2 - \dots - \alpha_p L^p)}_{A(L)} y_t = \mu + \varepsilon_t$$

gdzie: $A(L)$ – wielomian opóźnień

Badanie stopnia zintegrowania

- ▶ Wyznaczenie pierwiastków wielomianu charakterystycznego procesu [jeżeli znany jest proces generujący dane]
- ▶ *Testy pierwiastka jednostkowego* / testy stacjonarności

Model AR(1)

Badanie stacjonarności za pomocą pierwiastków wielomianu charakterystycznego

Wielomian charakterystyczny procesu AR(1):

$$1 - \alpha_1 z = 0$$

$z = \frac{1}{\alpha_1}$ - pierwiastek równania charakterystycznego

Proces AR(1) jest stacjonarny, jeżeli $|\alpha_1| < 1$, a więc jeśli pierwiastek wielomianu charakterystycznego $|\frac{1}{\alpha_1}| > 1$.

Model AR(1)

Przykład: AR(1)

$$y_t = \alpha_1 y_{t-1} + \varepsilon_t$$

$$y_t - \alpha_1 y_{t-1} = \varepsilon_t$$

$$y_t(1 - \alpha_1 L) = \varepsilon_t$$

$$y_t = \underbrace{\frac{1}{1 - \alpha_1 L}} \varepsilon_t$$

suma nieskończonego szeregu

A więc:

$$y_t = \varepsilon_t + \alpha_1 L \varepsilon_t + \alpha_1^2 L^2 \varepsilon_t + \alpha_1^3 L^3 \varepsilon_t + \dots$$

$$y_t = \varepsilon_t + \alpha_1 \varepsilon_{t-1} + \alpha_1^2 \varepsilon_{t-2} + \alpha_1^3 \varepsilon_{t-3} + \dots$$

Warunki stacjonarności dla procesu AR(p)

- ▶ Proces AR(p) jest stacjonarny jeśli wszystkie pierwiastki równania charakterystycznego:

$$1 - \alpha_1 L - \dots - \alpha_p L^p = 0$$


leżą poza kołem jednostkowym, tzn. są co do modułu > 1 .

- ▶ **Stacjonarny proces AR(p) można przedstawić jako MA(∞).**
 - W modelu AR bieżąca wartość szeregu zależy od p poprzednich, a na poprzednie składa się nieskończona liczba opóźnionych szoków (ε).
 - W modelu MA tych szoków model „widzi” tylko q .

Czym jest koło jednostkowe?

- ▶ Pierwiastki wielomianu mogą być liczbami zespolonymi, tzn. mieć część rzeczywistą **a** i urojoną **b** (**$a + bi$**).
- ▶ Można je przedstawić na płaszczyźnie jako punkt w przestrzeni dwuwymiarowej o współrzędnych (**a, b**).

- $|a + bi| = \sqrt{a^2 + b^2}$



- ▶ więc warunek stacjonarności/odwracalności $|a + bi| > 1$ oznacza
 - $a^2 + b^2 > 1^2$ (pole poza okręgiem o środku $(0; 0)$ i promieniu 1, czyli „kołem jednostkowym”).

Warunki stacjonarności dla procesu AR(p)

- ▶ Czy poniższy proces jest stacjonarny?

$$y_t = y_{t-1} + \varepsilon_t,$$

$$(1 - L)y_t = \varepsilon_t$$

- ▶ Równanie charakterystyczne to

$$1 - z = 0$$

- ▶ Pierwiastek równania wynosi $z = 1$ zatem proces jest niestacjonarny (tzw. unit root process)

Model MA(q)

► *MA* (ang. *moving average*):

- Model *MA* jest liniową kombinacją procesów białego szumu, a zatem y_t zależy od bieżącej i przeszłych wartości zaburzenia losowego będącego białym szumem.

$$\mathbf{MA}(q): y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q},$$

gdzie: $\varepsilon_t \sim WN$

Notacja wielomianu charakterystycznego:

$$y_t - \mu = \underbrace{(1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q)}_{B(L)} \varepsilon_t$$

gdzie: $B(L)$ – wielomian opóźnień

Własności procesu MA(q)

$$MA(q): y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q},$$

gdzie: $\varepsilon_t \sim WN$

- ▶ Wartość oczekiwana:

$$E(y_t) = \mu$$

- ▶ Wariancja:

$$Var(y_t) = \gamma_0 = (1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_q^2) \sigma^2$$

- ▶ Kowariancja:

$$Cov(y_t, y_{t-k}) = \gamma_k = \begin{cases} (\theta_k + \theta_{k+1}\theta_1 + \theta_{k+2}\theta_2 + \cdots + \theta_q\theta_{q-k})\sigma^2, & k = 1, 2, \dots, q \\ 0, & k > q \end{cases}$$

Własności procesu $MA(q)$

- ▶ Dla skończonej wartości q proces $MA(q)$ jest zawsze stacjonarny.

- ▶ Jeśli jest spełniony warunek odwracalności:

$$\forall_i |z_i| > 1$$

- gdzie z_i to pierwiastki równania charakterystycznego:

$$1 + \theta_1 L + \dots + \theta_q L^q = 0$$

- ▶ Wówczas proces $MA(q)$ można przedstawić w postaci procesu $AR(\infty)$.
- ▶ Każdy stacjonarny proces $AR(p)$ można przedstawić w postaci procesu $MA(\infty)$.

Zadanie – praca domowa

1. Pokazać, że model $AR(1)$ można przedstawić jako $MA(\infty)$. Sformułować odpowiedni warunek.
2. Pokazać, że model $MA(1)$ można przedstawić jako $AR(\infty)$. Sformułować odpowiedni warunek.

Model ARMA(p,q) – połączenie AR(p) i MA(q)

- ▶ Proces ARMA (autoregressive moving average process)

$$y_t = \mu + \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

$$E(\varepsilon_t) = 0 \quad \text{var}(\varepsilon_t) = \sigma^2$$

- ▶ Zakładamy, że innowacje ε_t są nieskorelowane:

- ▶ $E(\varepsilon_t, \varepsilon_s) = 0$ dla $t \neq s$

- ▶ W modelu takim całkowity błąd losowy:

- ▶ $u_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$ - jest skorelowany

Model ARMA można wówczas przedstawić jako

$$y_t = \mu + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \dots + \alpha_p y_{t-p} + u_t$$


Metody szacowania

- ▶ Jeśli $q = 0$; to model AR(p), można wyestymować MNK:

- ▶ Jeśli $q \neq 0$, czyli

$$y_t = \mu + \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p} + u_t$$

- ▶ Jest to model autoregresyjny ze skorelowanym błędem losowym



- ▶ Występowanie autokorelacji implikuje równoczesność i w efekcie brak zgodności estymatora MNK

- ▶ Należy zastosować estymatory MNW (Metoda Największej Wiarygodności) lub NMNK (Nieliniowa Metoda Najmniejszych Kwadratów).

Model ARIMA(p,d,q)

- ▶ Szeregi niestacjonarne...
 - **analiza wielowymiarowa** (kointegracja i model korekty błędem)
 - **analiza jednowymiarowa** - tworzymy model ARMA(p,q) na szeregu zróżnicowanym tyle razy, aby uzyskać jego stacjonarność:

$$\Delta Y_t = Y_t - Y_{t-1}$$
$$\Delta^2 Y_t = \Delta Y_t - \Delta Y_{t-1}$$

- **Model ARIMA(p,d,q):**

$$\Delta^d y_t = \mu + \alpha_1 \Delta^d y_{t-1} + \dots + \alpha_p \Delta^d y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

ARMA a ARIMA

Model ARMA jest szczególnym przypadkiem modelu ARIMA (z parametrem $d=0$).

Model ARIMAX

- ▶ ARIMAX - model ARIMA uzupełniony o zestaw egzogenicznych regresorów:

$$\Delta^d y_t = \mu + \beta x_t + \alpha_1 \Delta^d y_{t-1} + \dots + \alpha_p \Delta^d y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

Dziękuję za uwagę